MODELO DE PROPOSTA DE PROJETO
EA018

NOMES DO(S) ALUNO(S) PARTICIPANTE(S):	RA	CURSO
1.Anderson Agondi dos Santos Paschoalon	083233	**34AB**

ORIENTADOR: Diedre Stefanelli do Carmo

TEMA DO PROJETO: Otimização do Uso de Recursos Computacionais Heterogêneos para Aprendizado Profundo

RESUMO DO CRONOGRAMA DAS ATIVIDADES**

PERÍODO DE REALIZAÇÃO:		DESCRIÇÃO:
01-Setembro/ 2026	30-Setembro-2026	(1) Estudo da bibliografia levantada e início das atividades exploratórias. (2) Levantamento de treinamentos de *deep learning* que podem ser utilizados como métricas de benchmark e teste.
01-Outubro-2026	30-Outubro-2026	(1) Atividades exploratórias no laboratório, implementação e instalação das ferramentas e fechamento do escopo da pilha tecnológica. (2) Definição dos experimentos de infraestrutura a serem realizados. (3) Escrita do plano de trabalho.
01-Novembro-2026	30-Novembro-2026	(1) Fechamento do escopo da metodologia e da análise experimental. (2) Submissão do plano de trabalho
01-Dezembro-2026	15-Dezembro-2026	(1) Início de implementação da infraestrutura tecnológica proposta no plano.
01-Março-2027	30-Março-2027	(1) Implementação da infraestrutura tecnológica com escopo mais abrangente, envolvendo GPUs de diferentes granularidades de desempenho. (2) Início da escrita do relatório final.
01-Abril-2027	30-Abril-2027	(1) Automatização completa da implementação da infraestrutura como código para submissão de jobs de aprendizado profundo. (2) Início da realização de experimentos práticos quantificando experimentalmente os benefícios da metodologia proposta. (3) Continuação da escrita do relatório final
01-Maio-2027	30-Maio-2027	(1) Finalização da coleta dos resultados experimentais. (2) Análise dos resultados. (3) Finalização da escrita do relatório final.
01-Junho-2027	30-Junho-2027	(1) Finalização da análise experimental. (2) Revisão geral. (3) Entrega do relatório final

DATA: 28/08/2026

OBSERVAÇÕES:

* Para trabalhos em grupo cada participante deverá apresentar separadamente, o formulário preenchido e assinado.
** Incluir todo o cronograma do TCC, que será desenvolvido nas disciplinas EA018 e EA019.

OBJETIVOS:

O projeto visa implantar um piloto de gerenciamento de recursos computacionais heterogêneos, incluindo GPUs (placas de vídeo) comumente usadas em experimentos com aprendizado profundo. Utilizando uma pilha tecnológica Open-Source (como SGE ou Slurm), pretende-se melhorar o aproveitamento da infraestrutura disponível no laboratório MICLab do LCA por pesquisadores de graduação e pós-graduação. Objetivos específicos são:

- Reduzir Subutilização: otimizar o uso de recursos computacionais existentes, em especial GPUs e computadores mais modestos;
- Computação Distribuída: viabilizar experimentos utilizando recursos computacionais distribuídos, para possivelmente alcançar novos níveis de performance computacional aproveitando hardware já existente;
- Acelerar Execução de Experimentos: através de uma melhor gestão de compartilhamento de recursos, visamos reduzir o tempo de execução de experimentos por parte dos usuários (alunos);
- Aumento da Eficiência Computacional: melhorar a disponibilidade de capacidade de processamento, sem a necessidade de investimento adicional;
- Equidade no Acesso: o acesso à capacidade de processamento computacional deve ocorrer de forma justa entre os usuários, a partir da implementação de fila de execução de experimentos.

DESCRIÇÃO:

A pesquisa envolvendo aprendizado profundo envolve o uso de recursos computacionais pesados, nem sempre abundantes em laboratórios de pesquisa, especialmente no Brasil. O MICLab/LCA da FEEC compartilha recursos computacionais de alta capacidade com múltiplos alunos de doutorado e mestrado, o que resulta em atritos de definição da ordem de experimentos em hardware mais capaz, ao mesmo tempo que hardware "obsoleto" pode ficar abandonado. Além disso, a grande quantidade de dados envolvidos dificulta a execução de experimentos em recursos heterogêneos sem disperdicio de *storage*.

Esse projeto pretende atacar os dois problemas, implementando software de compartilhamento e organização de recursos computacionais pela rede, envolvendo filas de execução de scripts; experimentos com computação distribuída; e centralização de dados em Network Attached Storage (NAS) já presente no laboratório.

Inicialmente o projeto deverá ser feito através da definição de uma pilha tecnlogica OpenSource de gerenciamento de jobs em Clusters, muito provavelmente com o Slurm ou SGE como escalonador.

A implementação dessa infraestrutura deverá ser automatizada através do processo Infrastructure as Code (IaC), possibilitando a implantação posterior a todo o laboratório, bem como facilitando a manutenção das politicas estabelecidas. Aqui serão definidas políticas de Fair-share, ou seja, a distribuição controlada de recursos, e priorização de recursos entre diferentes usuários. A implantação desse tipo de política permite o aumento da eficiência computacional, e distribuição justa de recursos entre usuários. No plano de trabalho, serão definidos mais detalhes sobre a metodologia de estabelecimento da melhor solução para o problema, e a definição de experimentos visando comprovar que os quatro pontos listados como objetivos, foram de fato alcançados.

BIBLIOGRAFIA (se necessário):

GÉRON, Aurélien. **Mãos à obra: aprendizado de máquina com Scikit-Learn, Keras & TensorFlow**. 2. ed. Rio de Janeiro: Alta Books, 2021.

SCHEDMD. **Slurm Workload Manager**: Documentation. [S. l.]: SchedMD, 2026. Disponível em: https://slurm.schedmd.com/documentation.html. Acesso em: 21 ago. 2026

SCHEDMD. **Fair Tree Fairshare Plugin**: Slurm Workload Manager. [S. l.]: SchedMD, 2026. Disponível em: https://slurm.schedmd.com/fair_tree.html. Acesso em: 21 ago. 2026.

NVIDIA. **NVIDIA DeepOps**: Deployment guide for GPU clusters. [S. l.]: NVIDIA, 2024. Disponível em: https://github.com/NVIDIA/deepops. Acesso em: 21 ago. 2026.

MAJEE, Arindam. **DeepOps & SLURM**: Your GPU cluster guide: a guidance to build your own GPU cluster for deep learning. *arXiv preprint arXiv:2405.00030*, 2024. Kolkata: TCG CREST Institute of Advancing Intelligence, 2024. Disponível em: https://arxiv.org/abs/2405.00030. Acesso em: 21 ago. 2026.

WANG, Farui; ZHANG, Weizhe; LAI, Shichao; HAO, Meng; WANG, Zheng. Dynamic GPU energy optimization for machine learning training workloads. **IEEE Transactions on Parallel and Distributed Systems**, v. 33, n. 11, p. 2943-2954, 2022

Gentzsch, Wolfgang. "Sun grid engine: Towards creating a compute power grid." **Proceedings First IEEE/ACM International Symposium on Cluster Computing and the Grid**. IEEE, 2001.